



인간의 성장 발달과정을 모사한 인간지향적 AI 모델 개발

중간 발표

2025.11.13

한국전자통신연구원, 성균관대학교 (Brain / AI), 마인즈솔루션, 가천대학교

목차

- 연구 과제 개요
 - 목표 및 필요성
 - 구조 및 역할
- 과제 – 성균관대학교 AI Unit
 - 연구 내용 및 범위
 - Large World Model 평가지표 설계
- 향후 계획
- Appendix

연구 과제 개요

목표 및 필요성

목표

: 현실 세계의 경험을 통한 공간지능과 인과적 사고를 학습·이해하는 인간지향적 AI 모델 개발

→ 인간의 성장 단계별 인지 발달 특성을 반영한 데이터 모델링 및 LWM(Large World Model) 기반의 AI 프레임워크 설계

필요성

- 기존 LLM은 대규모 데이터 의존으로 경험 기반 추론과 논리적 사고 측면에서 한계가 존재함
- 에이전트 기반 자율적 의사결정 방식이 등장했지만 수행의 신뢰성과 인간 수준의 개입에 대한 한계가 여전히 존재
- 현 AI 모델은 입력-출력 중심의 학습에 치우쳐 있어 단계별 인지 발달 및 뇌 활동 간 연계 분석이 부족함
- 이러한 한계를 극복하기 위해 인간의 인지 과정을 반영한 새로운 개념의 인지 기반 AI 모델 개발과 평가 프레임워크 정립 필요

구조 및 역할



과제 - 평가 프레임워크 개발

연구 내용 및 범위

◆ 1차년도 : 모델 효용성 입증을 위한 다각도 검증 및 최적화

개발목표	개발내용
LWM 평가 프레임워크 초기 설계	• LWM 평가를 위한 <u>핵심 데이터 및 지표 수집 체계</u> 구축 • <u>평가 자동화</u>를 위한 모듈 간 연동 및 <u>워크플로우</u> 개발
AI Agent 기반 평가 개념 모델링	• <u>초기 평가 알고리즘</u> 개발 • LWM 평가 기준에 맞는 AI Agent <u>보상 모델 설계 및 학습</u> • LWM 성능 평가를 위한 AI Agent <u>시뮬레이션 환경</u> 구축
LWM 단계 정의 및 모델링	• AGI 능력 평가 <u>지표 정의 및 설계</u> • LWM 발전 수준을 구분할 수 있는 <u>단계별 모델링 수행</u>

월드모델 (World Model)

- 정의

세계에 대한 이해를 바탕으로 그것의 여러 측면을 시뮬레이션할 수 있는 AI 시스템

- 환경 예측 : 현재 상태를 바탕으로 환경이 앞으로 어떻게 변화할지 예측
- 결과 예측 : 에이전트의 특정 행동이 환경에 어떤 영향을 미칠지 미리 예측


- 역할

AI 에이전트가 현실 세계에서 직접 시행착오를 격지 않고도 내부적으로 환경을 시뮬레이션하며 미래를 예측, 계획 수행

- 월드 모델을 통해 AI 에이전트들의 풍부한 시뮬레이션 환경에서의 무제한 훈련 가능
- 월드 모델은 AGI로 향하는 길의 중요한 디딤돌

월드모델의 기본 구조와 작동 원리

- **V 모델 (Vision Model)** : 세상을 관찰하는 역할
외부 세계의 시각 정보를 압축해 내부 표현으로 변환 ex) VAE
 - **M 모델 (Memory Model)** : 기억과 예측 담당
현재 상태에서부터 다음 상태 시뮬레이션 ex) MDN-RNN
월드 모델의 핵심으로 시간적 역학 학습
 - **C 모델 (Controller)** : 행동 결정
예측된 결과를 기반으로 다음 행동을 선택하고 실행
- => V-M-C 구조를 통해 월드모델은 세상을 내적으로 상상하며 행동의 결과 예측 가능



기존 언어 모델(LLM)과 월드모델의 차이

	LLM(Large Language Model)	LWM(Large World Model)
Input	텍스트 중심 (언어, 문맥 정보)	영상, 동작, 상태 등 현실 환경 정보
Output	언어적 추론 결과 (답변, 요약, 명령 등)	미래 상태 예측 (다음 프레임, trajectory 등)
핵심 능력	언어적, 논리적 추론 지식 기반 reasoning	물리적, 공간적 추론 시각, 행동 기반 simulation
학습 방식	텍스트 기반 self-supervised learning	시각 행동 기반 predictive learning
한계	물리적 직관 부족 공간 인식 미약 실제 환경 변화 이해 부족	언어적 개념 이해 한계 추상적 reasoning 능력 부족
보완관계	세상을 '언어'로 설명하는 모델	세상을 '시뮬레이션'하며 이해하는 모델

대표 월드 모델


	모델	연구기관	설명	평가 지표
1	Navigation World Model	Meta AI (facebook research)	<u>탐색 및 네비게이션</u> 행동 데이터를 기반으로 미래 경로와 장면 예측하는 비디오 생성형 월드 모델	ATE, RPE, LPIPS, DreamSim, PSNR, FID, FVD
2	Cosmos	NVIDIA	텍스트, 이미지, 비디오 생성을 통합하여 로봇틱스를 위한 행동 조건 기반 시뮬레이션을 지원하는 <u>Physical AI용 통합</u> 월드 모델 프레임워크	PSNR, SSIM, Latent L2, FVD [Cosmos-Predict2.5-2B/robot/action-cond]
3	IRASim	ByteDance	로봇의 행동 궤적으로부터 비디오 결과를 예측하여, 정교한 <u>로봇-객체 상호작용</u> 의 고해상도 영상을 생성하는 로봇 조작용 월드 모델	PSNR, SSIM, Latent L2, FID, FVD

대표 월드 모델

1. NWM : Navigation World Model – CVPR(2025)

목표 : 시각-운동 능력을 갖춘 에이전트의 네비게이션 성능 향상

- 과거 관측 영상과 행동 시퀀스를 입력받아 에이전트의 이동 경로 및 시점 변화에 따른 미래 영상 프레임 생성
 - 시각 정보를 VAE 인코더로 latent space에 압축, 행동 정보를 time embedding으로 CDiT에 조건으로 입력
 - Conditional Diffusion Transformer (CDiT)가 시각 latent와 행동 latent를 융합하여 시간 축 상의 연속적 프레임 예측 수행




대표 월드 모델

1. NWM : Navigation World Model – CVPR(2025)

- 입력 : 과거 관측 영상 + 행동 시퀀스 메타데이터
- 출력 : 다음 시점 영상 및 경로 예측

[Inference Result on Recon dataset]



대표 월드 모델

2. Cosmos (NVIDIA – Cosmos-Predict2.5-2B/robot/action-cond)

목표 : 주어진 로봇 동작 시퀀스의 시각적 결과 예측

- 고해상도 및 물리적으로 일관성 있는 미래 영상 프레임을 생성
- Action Embedder MLP를 활용해 동작 시퀀스를 생성 과정에 주입
 - 동작 정보를 DiT의 시간 임베딩에 추가함으로써 주어진 동작 궤적을 충실히 따르는 프레임 생성 가능
- Cosmos-Predict2.5 파운데이션 모델 기반으로 구축
 - Diffusion Transformer(DiT) 백본과 Flow Matching 아키텍처 사용
 - 비디오 청크(video chunks)를 자가회귀적으로 생성, 전체 동작 궤적을 예측



대표 월드 모델


Image2World

▶ Input prompt

Input image	Output video
	bus_terminal.mp4 ▾ 

Video2World

▶ Input prompt


Input Video	Output Video
robot_pouring.mp4 ▾ 	robot_pouring.mp4 ▾ 

대표 월드 모델

2. Cosmos (NVIDIA – Cosmos-Predict2.5-2B/robot/action-cond)

- 입력 : 단일 관측 이미지 + 로봇 동작 시퀀스
- 출력 : 다음 시점 영상 프레임 예측 (자기회귀적)

[Inference Result on Bridge dataset]




대표 월드 모델

3. IRASim: A Fine-Grained World Model for Robot Manipulation – ICCV(2025)

목표 : 이전 관측 영상과 동작 궤적을 조건으로 하여 로봇-객체 간 상호작용을 정밀하게 시뮬레이션

- Frame-Ada 기반의 프레임 단위 동작 조건화(frame-level action-conditioning) 메커니즘 활용
 - 각 로봇 동작을 해당 비디오 프레임과 정렬 -> 조작 과제를 위한 정확하고 현실적인 궤적-비디오 예측 가능
- Diffusion Transformer(DiT) 기반 잠재 공간 위에 Frame-Ada 및 Video-Ada 모듈을 통합하여 구성
 - 시공간적 일관성과 장기 비디오 생성 효율성 확보




대표 월드 모델

3. IRASim: A Fine-Grained World Model for Robot Manipulation – ICCV(2025)

- 입력 : 이전 관측 영상 프레임 + 로봇 동작 시퀀스
- 출력 : 다음 시점 영상 프레임 시퀀스 예측

[Inference Result for short-trajectory video generation on Bridge dataset]



월드모델의 주된 공통 평가 지표

- **PSNR : Peak Signal-to-Noise Ratio**

- 실제 이미지와 예측된 이미지를 픽셀 단위 차이를 기반으로 유사도 측정
- 예측된 이미지 정확도 평가, 값이 높을수록 원본과 유사

- **SSIM : Structural Similarity Index Measure**

- 실제 이미지와 예측된 이미지의 명암, 구조, 대비를 종합적으로 비교하여 시각적 품질 평가
- 인간이 느끼는 유사도에 가까운 지표

- **FID : Fréchet Inception Distance**

- 실제 이미지와 생성 이미지 간의 특징 분포 차이 계산
- 시각적 사실성 평가, 값이 낮을수록 품질 우수

- **FVD : Fréchet Video Distance**

- FID를 영상 시퀀스로 확장한 지표, 시간적 일관성 및 이미지 품질 평가

⇒ 시각적 재현 품질(정확도·사실성·일관성)을 평가하기 위한 기준 -> **월드모델의 예측 능력** 정량적 검증

기존 평가지표의 한계점과 개선 필요성

- 세분화된 기준 평가 불가

- PSNR, SSIM, FID, FVD는 픽셀 단위 유사도, 통계적 분포 일치, 시간적 일관성에 초점을 둠
- 모델이 사용자 정의 기준을 얼마나 잘 따랐는지는 평가 못함 (ex : 물리적 타당성, 행동 일치성, 인과성 등)

- 의미적 정확성 평가 한계

- 생성된 영상이 실제 이미지와의 유사도는 높더라도 물리 법칙을 위반(ex : 물체가 벽을 통과, 비정상적인 중력 등)하거나 행동 결과(ex : 물체가 벽을 통과, 비정상적인 중력 등)가 어긋나는 경우를 반영하지 못함
- FVD는 시간적인 일치도는 포착 가능하지만 인과적 오류는 감지 못함

- 해석 가능한 피드백 부재

- 기존 지표는 단일 수치 점수만 제공, 개선 방향에 대한 구체적 피드백 제시 불가
Ex) FID가 낮을 때의 원인이 색상 분포, 질감, 객체 형태 중 어디에 있는지 알 수 없음

인간 지향적 평가의 필요성

- 기존 평가지표의 한계 : 결과 중심 평가로 세밀한 의미 분석, 인과적 해석이 어려움
- 현재 AI의 한계 : 인간 수준의 일관된 가치 판단, 이해 부족
 - ChatGPT, Gemini, Claude 등은 고성능이지만 인과적 사고 · 일관성 · 가치 이해 능력은 여전히 제한적

⇒ 인간의 사고 과정과 판단 기준을 반영한 동적 평가 체계 필요

- 이해력(Understanding) : 장면 간의 인과 관계 및 물리적 일관성, 정합성 평가
- 적응력(Adaptation) : 다양한 상황에서도 일관된 평가 수행

새로운 평가 프레임워크

- **문제점**

- 기존 평가지표(PSNR, FVD, etc.)는 **픽셀 수준의 정확도**에만 집중되어 있으며 **단일 수치**로만 표현되어 의미적 해석이 어려움

- **목표**

- 픽셀 유사도 뿐 아니라, 장면의 의미와 맥락을 이해하며 평가할 수 있는 새로운 프레임워크를 개발
- 평가 결과를 사람이 이해할 수 있는 형태로 상세히 제공

- **핵심 개념**

- Vision-Language Model (VLM)을 AI 평가자로 활용하여 생성된 비디오를 보고 이해하며 품질을 평가하는 프레임워크 구축


새로운 평가 프레임워크

- **방법론**

- VLM 기반의 AI Agent 평가
- 평가모델 : COSMOS-Reason 1 (a fine-tuned Qwen2.5-VL-7B model)
- 평가 절차 : 비디오당 **다중 반복 평가(Multi-Trial, 예: 5회 반복)**를 수행하여 결과의 안정성과 신뢰도 확보
 - 각 trial마다 AI Agent가 6개의 dimension에 대해 Yes/No(Anomaly / No Anomaly) 판단
- 출력 결과 : Overall score + Dimensional radar chart + HTML detailed report

새로운 평가 프레임워크

Prompt-Driven VLM Evaluation Framework



새로운 평가 프레임워크

■ 프롬프트 평가 기준

- 작업 목표 일관성 : Task Goal Consistency
ex) 로봇이 의도한 작업(조작, 이동 등)을 올바르게 수행하는가?
- 객체 상호작용 정확도 : Object Interaction Accuracy
ex) 올바른 객체를 조작하는가?
- 물리적 타당성 : Physical Plausibility
ex) 영상이 중력, 충돌 등의 실제 물리 법칙을 따르는가?
- 시간적 일관성 : Temporal Coherence
ex) 프레임 간 움직임이 부드럽고 시간 흐름에 따라 논리적으로 연결되는가?
- 시각적 안정성과 아티팩트 : Visual Stability and Artifacts
ex) 깜빡임, 왜곡, 블러, 텍스처 튜 현상 등 시각적 오류가 존재하는가?
- 전반적 시각적 사실성 : Overall Visual Realism
ex) 장면이 전반적으로 사실적이고 자연스럽게 보이는가?

새로운 평가 프레임워크


Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Summary



Trial 5번 반복 평가 진행 결과

전체 평가 차원 중 1개라도 비정상 평가 받은 trial : 1회

전체 평가 차원 중 모두 정상 평가 받은 trial 횟수 : 4회

Dimension Scores

Task Goal Consistency	80% (No Anomaly Rate)
Object Interaction Accuracy	80% (No Anomaly Rate)
Physical Plausibility	80% (No Anomaly Rate)
Temporal Coherence	80% (No Anomaly Rate)
Visual Stability and Artifacts	100% (No Anomaly Rate)
Overall Visual Realism	80% (No Anomaly Rate)

5번의 반복 평가로 도출된
각 평가 항목별 No Anomaly(정상) 비율

새로운 평가 프레임워크

Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Detailed Analysis (5 trials)

Trial 1

Trial 5번 반복 평가 진행 중 1번째 trial 결과 : **No Anomaly**

: 모든 평가 차원 결과에서 이상 없음 판정

Overview: The video shows a robotic arm interacting with various objects placed on a wooden table. The setup includes an orange cloth, a metal bowl, and a cylindrical object resembling a piece of bread. The robotic arm moves into the frame, interacts with the orange cloth, and then exits. The intended task appears to involve manipulating these objects, possibly for cleaning or organizing purposes.

Task Goal Consistency - No

The robotic arm is supposed to interact with the objects on the table. It picks up the orange cloth and moves it across the surface. However, the task goal isn't clear but seems to involve manipulating the cloth. The main issue is that the task goal isn't explicitly defined, making it difficult to assess consistency. However, assuming the goal was to move the cloth, the action is consistent. No anomalies detected here.

Object Interaction Accuracy - No

The robotic arm accurately grasps the orange cloth and drags it across the table. The interaction is smooth, with no unexpected releases or misalignments. The arm's movement aligns well with its purpose of handling the cloth. No anomalies detected.

Physical Plausibility - No

Gravity behaves realistically; the cloth stays on the table when dragged. Collisions between the arm and the table appear natural. The arm's mechanical components move logically without any deformation or penetration through solid surfaces. No anomalies detected.

Temporal Coherence - No

The frames show continuous and smooth motion. The arm's movement is consistent, with no sudden jumps or teleportation. The sequence progresses logically without any temporal discontinuities. No anomalies detected.

Visual Stability and Artifacts - No

There are no visible distortions like flickering, blurring, or texture jumps. The images remain stable throughout the sequence. No artifacts observed.

Overall Visual Realism - No

The robotic arm interacts naturally with the objects, maintaining a realistic appearance. The environment remains consistent, with no unexpected changes or glitches. The overall scene looks coherent and plausible. No anomalies detected.

Final Answer: no

새로운 평가 프레임워크

Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Trial 5번 반복 평가 진행 중 2번째 trial 결과 : **Anomaly**

Trial 2

: 도출된 모든 평가 차원 결과에서 1개 이상의 Anomaly 판단

Overview: The video showcases a robotic arm interacting with various objects on a wooden surface. The setup includes an orange cloth, a metal bowl, and a cylindrical object resembling a can of soup. The primary action involves the robotic arm manipulating the orange cloth, moving it across the table, and then placing a yellow spoon on top of it. The environment appears to be a controlled workspace, likely designed for robotics testing or demonstration purposes.

Task Goal Consistency - Yes

The task goal seems to involve the robotic arm organizing or preparing items on the table. This could be part of a larger sequence involving placement, arrangement, or demonstration of objects. However, the final action of placing a spoon on the cloth may not align with a clear, defined task goal unless it's part of a larger context not provided here. The spoon's appearance and placement seem abrupt and unrelated to the initial setup.

Object Interaction Accuracy - Yes

The robotic arm accurately grasps and moves the orange cloth, adjusting its position smoothly. The interaction with the cloth is realistic, with proper friction and weight response. The arm's movement towards the spoon is deliberate, but the spoon itself was not present in the initial setup, suggesting an unexpected element introduced later. The spoon's sudden appearance and placement on the cloth lack prior context, making its interaction seem arbitrary.

Physical Plausibility - Yes

The robotic arm and objects maintain realistic gravitational behavior. The cloth folds naturally under the arm's manipulation, and the soup can remains stationary as expected. The introduction of the spoon introduces plausibility issues. Its placement on the cloth doesn't align with any visible action that would place it there, suggesting a possible glitch or unintended manipulation.

Temporal Coherence - Yes

The frames depict consistent motion, with the robotic arm smoothly transitioning between tasks. The cloth's movement is logical and follows the arm's trajectory. The spoon's appearance disrupts the temporal coherence. Its sudden presence creates a visual discontinuity and disrupts the flow of actions depicted.

Visual Stability and Artifacts - No

The video lacks noticeable flickering, blurring, or texture jumps apart from the spoon's introduction. The visual stability of the table, objects, and robotic arm is maintained throughout the sequence except for the spoon-related anomaly.


Overall Visual Realism - Yes

The overall scene maintains a realistic representation of a robotic manipulation task. However, the unrealistic placement of the spoon detracts from the realism. The spoon should ideally have been part of a previous step or introduced through a clear action, rather than appearing abruptly.


Final Answer: yes

새로운 평가 프레임워크


■ Prompt Dimensional Scores



(a) NWM



(b) COSMOS



(c) IRASim

새로운 평가 프레임워크

- 평가 결과

- Note:** 점수가 높을수록 비디오의 이상 현상(Anomaly)이 적고, 시각적·물리적 일관성이 우수함을 의미
- Total Score = (각 비디오 trial 결과의 정상 비율)의 전체 비디오 평균
- 각 평가 차원 Score = 모든 비디오의 dimension score 평균

모델	Total Score	Object Interaction Accuracy	Overall Visual Realism	Physical Plausibility	Task Goal Consistency	Temporal Coherence	Visual Stability & Artifacts
IRASim	0.70	0.75	0.86	0.89	0.74	0.93	0.96
Cosmos	0.61	0.68	0.79	0.82	0.63	0.89	0.92
Navigation World Model	0.52	0.57	0.73	0.79	0.59	0.83	0.88

향후 계획

향후 계획

- **AI Agent 기반 평가 시스템 확장**
 - 현재 구축된 평가 프레임워크를 기반으로 자기 평가(self-evaluation) 안정성 향상
 - 에이전트 평가 프로토타입 구현
- **LWM 단계별 평가 프레임워크 검증**
 - 시뮬레이션 실험을 통한 성능 및 타당성 검증 진행

Appendix

현재 AI의 인간 대비 한계

- ChatGPT, Gemini, Claude 등 초거대 모델이 다양한 언어·추론 능력을 보이지만 여전히 인간 수준의 사고 일관성, 감정 이해, 가치 판단에서 한계가 존재함
 - 인지적 한계 : 장기 맥락 유지 불안정, 일관성 부족, 편향 존재
 - 행동적 한계 : 새로운 상황, 복잡한 정보들이 주어지는 경우, 부족한 적응력으로 인한 환각 현상 및 편향 증가
 - 높은 평가 비용 및 낮은 확장성

현재 AI의 인간 대비 한계

■ MLLM-as-a-Judge (ICML, 2024)

- Multimodal Large Language Model이 평가자로서 얼마나 일관적이고 공정하게 판단할 수 있는지를 검증
- MLLM은 인간 수준의 사고 일관성 및 가치 판단에서 아래와 같은 한계를 보임




Figure 4. Pair Comparison density (Left) and Scoring Evaluation density (Right) of different MLLMs judgments and human annotations.




Figure 5. Consistency checking on 6 repetitions of experiments on GPT-4V (Left) and Gemini (Right). GPT-4V outperforms Gemini with a relatively higher ratio for high consistency.

⇒ 현재까지의 AI는 인간 수준의 사고 일관성, 맥락 판단, 가지 중립성 측면에서 여전히 한계 존재

1차년도 연구개발과제 세부 항목별 현재 진행상황

1차년도 연구 개발 과제

- ① LWM 평가를 위한 핵심 데이터 및 지표 수집 체계 구축 → Bridge Dataset 기반 평가용 데이터셋 구축 완료
 - ② 평가 자동화를 위한 모듈 간 연동 및 워크플로우 개발
 - ③ 초기 평가 알고리즘 개발
 - ④ LWM 성능 평가를 위한 AI Agent 시뮬레이션 환경 구축
- LWM 평가 프레임워크 설계 및 실행 파이프라인 구축 완료
- ⑤ LWM 평가 기준에 맞는 AI Agent 보상 모델 설계 및 학습 → 6가지 평가 기준 중 취약 항목을 프롬프트 설계로 보완
 - ⑥ AGI 능력 평가 지표 정의 및 설계 → VLM 프롬프트 기반 스코어링을 활용한 종합적 AGI 평가 체계 구축
 - ⑦ LWM 발전 수준을 구분할 수 있는 단계별 모델링 수행 → 산출된 종합 점수를 기반으로 단계별 발전 수준 차등 구분 가능

NWM Bridge Dataset 파인튜닝 및 예측 결과

[Inference Result on Bridge dataset]

Ground Truth



Predict Result



T=1

T=2

T=3

T=4

T=5

T=6

T=7

T=8

T=16

Ground Truth



Predict Result



T=1

T=2

T=3

T=4

T=5

T=6

T=7



T=8

T=16

Cosmos Bridge Dataset 예측 결과

[Inference Result on Bridge dataset]






Ground Truth



...



Predict Result



T=1

T=2

T=3

T=4

T=5

T=6

T=7

T=8

T=16

Ground Truth



...



Predict Result



T=1

T=2

T=3

T=4

T=5

T=6

T=7


T=8

T=16


IRASim Bridge Dataset 예측 결과

[Inference Result on Bridge dataset]

Ground Truth



Predict Result



T=1

T=2

T=3

T=4

T=5

T=6

T=7

T=8

T=15

Ground Truth



Predict Result



T=1

T=2

T=3

T=4

T=5

T=6

T=7

T=8

T=15

새로운 평가 프레임워크

Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Summary

1

Anomaly Detected

4

No Anomaly

5

Total Parsed

Dimension Scores

Task Goal Consistency	80% (No Anomaly Rate)
Object Interaction Accuracy	80% (No Anomaly Rate)
Physical Plausibility	80% (No Anomaly Rate)
Temporal Coherence	80% (No Anomaly Rate)
Visual Stability and Artifacts	100% (No Anomaly Rate)
Overall Visual Realism	80% (No Anomaly Rate)

새로운 평가 프레임워크

Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Detailed Analysis (5 trials)

Trial 1

Overview: The video shows a robotic arm interacting with various objects placed on a wooden table. The setup includes an orange cloth, a metal bowl, and a cylindrical object resembling a piece of bread. The robotic arm moves into the frame, interacts with the orange cloth, and then exits. The intended task appears to involve manipulating these objects, possibly for cleaning or organizing purposes.

Task Goal Consistency - No

The robotic arm is supposed to interact with the objects on the table. It picks up the orange cloth and moves it across the surface. However, the task goal isn't clear but seems to involve manipulating the cloth. The main issue is that the task goal isn't explicitly defined, making it difficult to assess consistency. However, assuming the goal was to move the cloth, the action is consistent. No anomalies detected here.

Object Interaction Accuracy - No

The robotic arm accurately grasps the orange cloth and drags it across the table. The interaction is smooth, with no unexpected releases or misalignments. The arm's movement aligns well with its purpose of handling the cloth. No anomalies detected.

Physical Plausibility - No

Gravity behaves realistically; the cloth stays on the table when dragged. Collisions between the arm and the table appear natural. The arm's mechanical components move logically without any deformation or penetration through solid surfaces. No anomalies detected.

Temporal Coherence - No

The frames show continuous and smooth motion. The arm's movement is consistent, with no sudden jumps or teleportation. The sequence progresses logically without any temporal discontinuities. No anomalies detected.

Visual Stability and Artifacts - No

There are no visible distortions like flickering, blurring, or texture jumps. The images remain stable throughout the sequence. No artifacts observed.

Overall Visual Realism - No

The robotic arm interacts naturally with the objects, maintaining a realistic appearance. The environment remains consistent, with no unexpected changes or glitches. The overall scene looks coherent and plausible. No anomalies detected.

Final Answer: no

새로운 평가 프레임워크

Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Trial 2

Overview: The video showcases a robotic arm interacting with various objects on a wooden surface. The setup includes an orange cloth, a metal bowl, and a cylindrical object resembling a can of soup. The primary action involves the robotic arm manipulating the orange cloth, moving it across the table, and then placing a yellow spoon on top of it. The environment appears to be a controlled workspace, likely designed for robotics testing or demonstration purposes.

Task Goal Consistency - Yes

The task goal seems to involve the robotic arm organizing or preparing items on the table. This could be part of a larger sequence involving placement, arrangement, or demonstration of objects. However, the final action of placing a spoon on the cloth may not align with a clear, defined task goal unless it's part of a larger context not provided here. The spoon's appearance and placement seem abrupt and unrelated to the initial setup.

Object Interaction Accuracy - Yes

The robotic arm accurately grasps and moves the orange cloth, adjusting its position smoothly. The interaction with the cloth is realistic, with proper friction and weight response. The arm's movement towards the spoon is deliberate, but the spoon itself was not present in the initial setup, suggesting an unexpected element introduced later. The spoon's sudden appearance and placement on the cloth lack prior context, making its interaction seem arbitrary.

Physical Plausibility - Yes

The robotic arm and objects maintain realistic gravitational behavior. The cloth folds naturally under the arm's manipulation, and the soup can remains stationary as expected. The introduction of the spoon introduces plausibility issues. Its placement on the cloth doesn't align with any visible action that would place it there, suggesting a possible glitch or unintended manipulation.

Temporal Coherence - Yes

The frames depict consistent motion, with the robotic arm smoothly transitioning between tasks. The cloth's movement is logical and follows the arm's trajectory. The spoon's appearance disrupts the temporal coherence. Its sudden presence creates a visual discontinuity and disrupts the flow of actions depicted.

Visual Stability and Artifacts - No

The video lacks noticeable flickering, blurring, or texture jumps apart from the spoon's introduction. The visual stability of the table, objects, and robotic arm is maintained throughout the sequence except for the spoon-related anomaly.

Overall Visual Realism - Yes

The overall scene maintains a realistic representation of a robotic manipulation task. However, the unrealistic placement of the spoon detracts from the realism. The spoon should ideally have been part of a previous step or introduced through a clear action, rather than appearing abruptly.

Final Answer: yes

새로운 평가 프레임워크

Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Trial 3

Overview: The video shows a robotic arm interacting with various objects on a wooden table. Initially, the arm is positioned above an orange cloth. The arm then moves down, grasps the cloth, lifts it slightly, and then places it back on the table. A metal bowl and a loaf of bread are present on the table but remain stationary throughout the sequence. The setting appears to be a kitchen or workshop with a clean and organized backdrop.

Task Goal Consistency - No

The task goal is to assess whether the robot successfully performed the intended manipulation. The intended action seems to involve manipulating the orange cloth using the robotic arm. The robotic arm does grasp and move the cloth as expected, indicating that the primary task goal is achieved correctly. There are no apparent deviations from the intended task.

Object Interaction Accuracy - No

The robotic arm interacts with the orange cloth, lifting and repositioning it. The cloth behaves realistically under the influence of the arm's grip, showing natural deformation when lifted and placed back down. The interaction between the arm and the cloth is accurate, with no signs of penetration or unrealistic movement. The cloth remains intact and maintains its form throughout the sequence.

Physical Plausibility - No

The robotic arm operates within expected physical constraints, moving smoothly and logically. Gravity affects the cloth naturally when lifted and placed down. The metal bowl and bread remain stationary and unaffected by the arm's movements, adhering to expected physical behavior. No unrealistic deformations or ghosting occur in the objects or the environment.

Temporal Coherence - No

The robotic arm's movements are temporally consistent, progressing logically from one action to another. Each step in the sequence (moving towards the cloth, grasping, lifting, placing) follows a natural progression. There are no sudden jumps, flips, or unexpected changes in motion direction or speed.

Visual Stability and Artifacts - No

The video displays visual stability with no noticeable distortions, blurring, or texture jumps. The images remain clear and coherent throughout the sequence. The robotic arm and objects maintain their intended shapes and positions without any abrupt transformations.

Overall Visual Realism - No

The overall scene appears realistic, with the robotic arm functioning as expected in a controlled environment. The objects on the table interact naturally with the arm and each other. The setting is consistent with a typical kitchen or workshop, featuring a sturdy table and appropriate lighting.

Final Answer: no

새로운 평가 프레임워크

Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Trial 4

Overview: The video showcases a robotic arm interacting with various objects on a wooden surface. Initially, the robotic arm is positioned above an orange cloth, a metal bowl, and a white bottle. The robot moves its grippers down towards the orange cloth, makes contact, and begins to drag it across the table. The cloth slides past the metal bowl and the white bottle, ending up near the edge of the table. The background features a wall with a light switch and a glimpse of what appears to be a kitchen area.

Task Goal Consistency - No

The task goal seems to involve manipulating the orange cloth using the robotic arm. The robot successfully moves the cloth across the table, which aligns with the intended manipulation task. There are no apparent task-oriented anomalies in terms of the robot's action versus the expected outcome.

Object Interaction Accuracy - No

The robotic arm accurately grasps the orange cloth and drags it. The interaction between the grippers and the cloth looks plausible, with no signs of penetration or unrealistic movement. The cloth responds appropriately to the force applied by the robot, moving smoothly along the table surface.

Physical Plausibility - No

Gravity behaves realistically; the cloth moves consistently with the force applied by the robot and does not float or exhibit any unusual motion. Collisions occur naturally when the cloth interacts with the metal bowl and the white bottle. The objects don't deform unrealistically, and their positions change logically as the cloth is dragged.

Temporal Coherence - No

The frames progress smoothly, with the robotic arm's movement being continuous and consistent. There are no sudden jumps or unexpected changes in motion direction that would suggest temporal incoherence.

Visual Stability and Artifacts - No

No visual distortions such as flickering, blurring, or texture jumps are observed. The objects maintain their appearance and position appropriately throughout the sequence.

Overall Visual Realism - No

The video depicts a realistic manipulation scene where the robotic arm interacts with everyday objects on a table. The movements are plausible, and the environment remains stable, contributing to a coherent and believable scenario.

Final Answer: no

새로운 평가 프레임워크

Cosmos-Reason1 Video Analysis Report

File: 304_chunk.mp4

Video



Trial 5

Overview: The video showcases a robotic arm interacting with various objects on a wooden surface. The setup includes an orange cloth, a metal bowl, and a cylindrical object resembling a can of soup. The robotic arm moves into the frame, interacts with the orange cloth, and then lifts it slightly. The environment appears clean and organized, with a focus on the robot's manipulation tasks.

Task Goal Consistency - No

The robotic arm is designed to interact with the objects on the table. It moves towards the orange cloth, grasps it, and lifts it slightly off the surface. This aligns with the expected functionality of a robotic arm in a controlled environment. There are no visible deviations from the intended task.

Object Interaction Accuracy - No

The robotic arm accurately grasps the orange cloth and lifts it. The cloth behaves as expected under gravity, folding slightly when lifted. The metal bowl and cylindrical object remain stationary throughout the sequence, indicating proper collision detection and avoidance.

Physical Plausibility - No

The robotic arm's movements are smooth and consistent with real-world physics. The cloth deforms naturally when lifted, and there are no signs of penetration or unrealistic behavior. The objects maintain their structural integrity, and the interactions appear logical.

Temporal Coherence - No

The frames progress smoothly, with the robotic arm's actions following a logical sequence. The cloth is lifted gradually, and the arm's position changes consistently with its intended function. There are no sudden jumps or unexpected motions.

Visual Stability and Artifacts - No

The video maintains visual stability throughout the sequence. There are no instances of flickering, blurring, or texture jumps between frames. The objects and the robotic arm retain their clarity and form consistently.

Overall Visual Realism - No

The video presents a realistic depiction of a robotic manipulation task. The objects behave according to physical laws, and the robotic arm's actions are precise and deliberate. The overall scene appears coherent and plausible.

Final Answer: no

World Model 기존 평가지표 결과

모델	PSNR ↑	SSIM ↑	FID ↓	FVD ↓
Navigation World Model	15.50	0.525	78.09	31.07
Cosmos	24.55	0.844	25.13	143.45
IRASim	25.34	0.834	10.52	23.35